YBS 319 - Yapay Zekâ ve Öğrenen Algoritmalara Giriş
-Yapay Zekâyı Tanımlamak-

Zekâ tek bir yetenek değildir

Algılama, öğrenme, akıl yürütme, dil kullanma ve planlama farklı yeteneklerdir. Bir makine tek görevde üstün olup gündelik işlerde yetersiz kalabilir.

"Makine gerçekten düşünüyor mu?" yerine mühendislikte somut sorular sorarız:

- Sistem hangi görevi yerine getiriyor?
- Hangi koşullarda başarılı sayılıyor?
- Ortam değiştiğinde davranışı ne oluyor?
- Hatasının etkisi ve sorumluluğu kime ait?

1. Yapay zekâyı tanımlamanın dört yolu (Russell ve Norvig)

	İNSAN ÖLÇÜTÜ	RASYONELLİK ÖLÇÜTÜ
DÜŞÜNME	**İnsan gibi düşünen** İnsan zihninin problem çözme sürecini modellemeye çalışır. Bilişsel modelleme · Newell–Simon GPS	**Rasyonel düşünen** Doğru öncüllerden mantıksal olarak geçerli sonuca ulaşır. Düşüncenin yasaları · klasik kıyas
DAVRANMA	**İnsan gibi davranan** Dışarıdan gözlenen davranışın insana benzemesine odaklanır. Turing testi	**Rasyonel davranan** Amaç ve çevreye göre beklenen en uygun eylemi seçer. Rasyonel ajan · alanın baskın standardı

Dört kutu tarihsel aşamalar değildir; aynı soruya alternatif araştırma hedefleridir. Birbirini dışlamaz, her biri farklı bir başarı ölçütü kurar.

İnsan gibi davranma: Turing testi

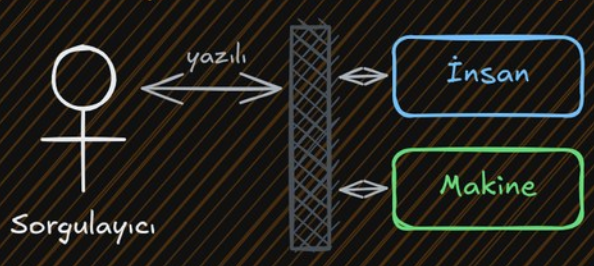

Sorgulayıcı, insan ile makineyi güvenilir biçimde ayırabiliyor mu?

Soyut bir soruyu ("Makineler düşünebilir mi?") sınanabilir bir davranışa çevirdiği için değerlidir.

× Bilinç testi değildir; insan gibi yanıt vermek, iç mekanizmanın insana benzemesini gerektirmez.

Rasyonel düşünme: düşüncenin yasaları

ÖNCÜL 1 — Bütün insanlar ölümlüdür

ÖNCÜL 2 — Sokrates insandır

SONUÇ — Sokrates ölümlüdür

* Gerçek dünya bilgisi çoğu zaman eksik ve belirsizdir.
* Geçerli çıkarımı bulmak hesaplama açısından çok pahalı olabilir.
* Geçerli ≠ doğru: "Bütün balıklar uçar; hamsi balıktır; öyleyse hamsi uçar." Biçim geçerli, öncül yanlış.

2. Rasyonel davranma: rasyonel ajan

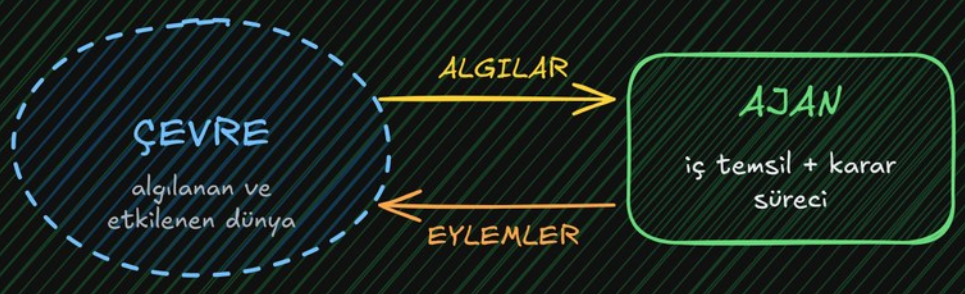

Her algı dizisi için, ön bilgi ve mevcut eylemler altında performans ölçütünü en çok artırması beklenen eylemi seçer.

Refleks, arama, öğrenme veya olasılıksal karar da uygun eylem üretebilir; insana benzemek gerekmez.

Rasyonellik bağlama bağlıdır, dört unsura dayanır:

- **01 Performans ölçütü** — Başarı hangi sonuçlarla ölçülüyor?
- **02 Ön bilgi** — Ajan çevre hakkında ne biliyor?
- **03 Eylem kümesi** — Hangi müdahaleleri yapabiliyor?
- **04 Algı dizisi** — Karar anına kadar ne gözledi?

Rasyonellik — Eldeki kanıta göre beklenen performansı artıran seçim

≠ Kusursuzluk — Sonradan en iyi olduğu görülen sonucu seçmek

≠ Her şeyi bilme — Eylemlerin sonucunu önceden kesin bilmek

Kötü sonuç, karar anında iyi kanıta dayanan bir eylemi otomatik olarak irrasyonel yapmaz.

3. Güncel ve işlevsel bir tanım (OECD, 2024 — sadeleştirilmiş)

"Belirli amaçlar doğrultusunda aldığı girdilerden nasıl bir tahmin, içerik, öneri, karar veya eylem üreteceğini çıkaran makine tabanlı sistem."

Amaç	Girdi	Çıkarım	Çıktı	Çevre	Özerklik
Neyi başarmaya çalışıyor?	Hangi bilgi veya sinyali alıyor?	Girdiden çıktıya nasıl geçiyor?	Tahmin, içerik, öneri, karar, eylem	Fiziksel ya da sanal dünyada nereyi etkiliyor?	İnsandan ne ölçüde bağımsız?

Bu tanım makine öğrenmesini zorunlu tutmaz: açık kurallardan çıkarım yapan sistemler de yapay zekâ kapsamında olabilir.

! Tanımlar "iyi" ya da "kötü" listesi değildir. Önemli olan, bir sisteme yapay zekâ dediğimizde hangi başarı ölçütünü kullandığımızı açıkça söylemektir.

YBS 319 - Yapay Zekâ ve Öğrenen Algoritmalara Giriş
-Temel Ayrımlar ve Kavramlar-

1. Otomasyon, yapay zekâ ve makine öğrenmesi

OTOMASYON

Bir işi insan müdahalesini azaltarak kurallar, yazılım veya makinelerle yürütür.

Saatli yedekleme · sabit IF kuralı · sensörle açılan kapı

YAPAY ZEKÂ

Algılama, çıkarım, arama, planlama, dil, öğrenme, tahmin veya karar gibi görevleri yerine getirir.

Uzman sistemi · satranç araması · öneri sistemi

MAKİNE ÖĞRENMESİ

Her davranışın açıkça yazılması yerine verideki örüntülerden model oluşturur.

Sahtekârlık modeli · talep tahmini · görüntü sınıflandırma

Bu üç kavram örtüşebilir; hiçbiri diğerinin zorunlu alt kümesi değildir.

Öğrenilmiş bir spam modelinin e-postayı otomatik taşıması hem makine öğrenmesi hem otomasyondur.

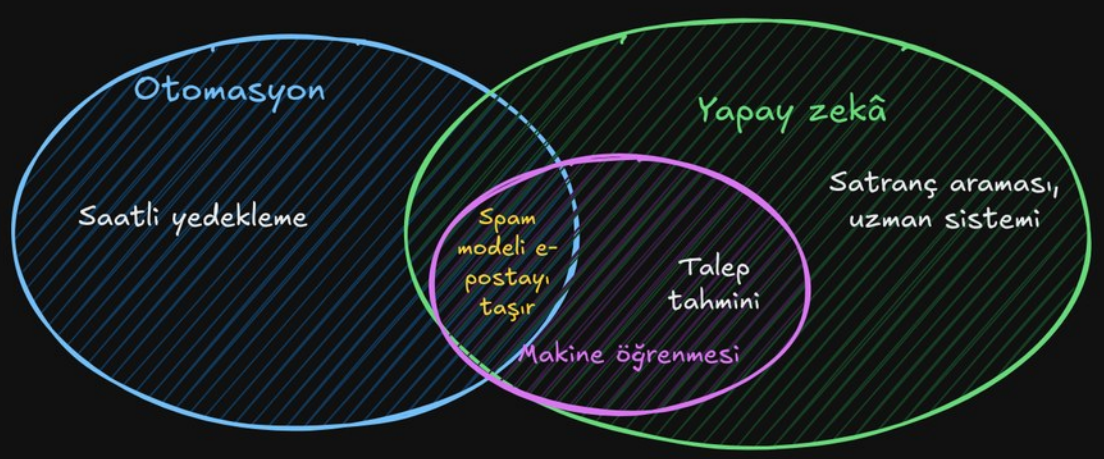

Makine öğrenmesi, yapay zekâ içinde önemli bir yöntem ailesidir.

2. Açık kurallar ve veriden öğrenme

	Açık kural yaklaşımı	Veriden öğrenme yaklaşımı
Bilgi	Uzman veya geliştirici kurallara dönüştürür	Örnekler ve örüntüler üzerinden modele taşınır
Güncelleme	Kural değişince sistem doğrudan güncellenir	Yeniden eğitim veya uyarlama ile değişir
Açıklama	Kural zinciri gösterilerek yapılabilir	Modele göre daha zor olabilir
Güçlü olduğu yer	Açık politika, mevzuat, az sayıda istisna	Elle yazılamayacak karmaşık örüntüler
Temel risk	Eksik, çelişkili veya eskimiş kurallar	Yanlış ya da değişmiş veri, zayıf genelleme

İkisi rakip değildir: bir kredi sisteminde mevzuat kuralları açıkça uygulanırken risk örüntüsü öğrenilmiş modelle tahmin edilebilir.

3. Eğitim, çıkarım ve genelleme

1 Eğitim → **2 Çıkarım** → **3 Genelleme**

1 Eğitim

Örnek veriler ve hedef ölçüt kullanılarak model parametreleri ayarlanır.

2 Çıkarım

Eğitilmiş model yeni bir girdiye çıktı üretir. Çoğu kullanımda eğitim tekrarlanmaz.

3 Genelleme

Model daha önce görmediği benzer örneklerde işe yarayan örüntüyü kullanır.

Model eğitim verisini ezberleyebilir, geçmişte kusursuz görünüp yeni müşterilerde başarısız olabilir. Asıl soru: geçmişi mi tekrar ediyor, yoksa yeni durumda işe yarayan ilişkiyi mi öğreniyor?

4. Tahmin, öneri ve karar aynı şey değildir

TAHMİN

Geleceğe veya bilinmeyene ilişkin değer üretir.

"Müşterinin ayrılma olasılığı %72"

→

ÖNERİ

Alternatiflerden birini insana sunar.

"Bu müşteri elde tutma ekibince aranmalı"

→

KARAR

Sonucu doğrudan uygular veya başka sisteme uygulatır.

"Müşteriye otomatik teklif gönder"

insan üzerindeki doğrudan etki ve risk artar

Yanlış bir tahmin analisti etkiler. Aynı tahmin otomatik ret kararına bağlandığında kişi doğrudan etkilenir.

5. Yapay zekâ, makine öğrenmesi, derin öğrenme ve üretken YZ

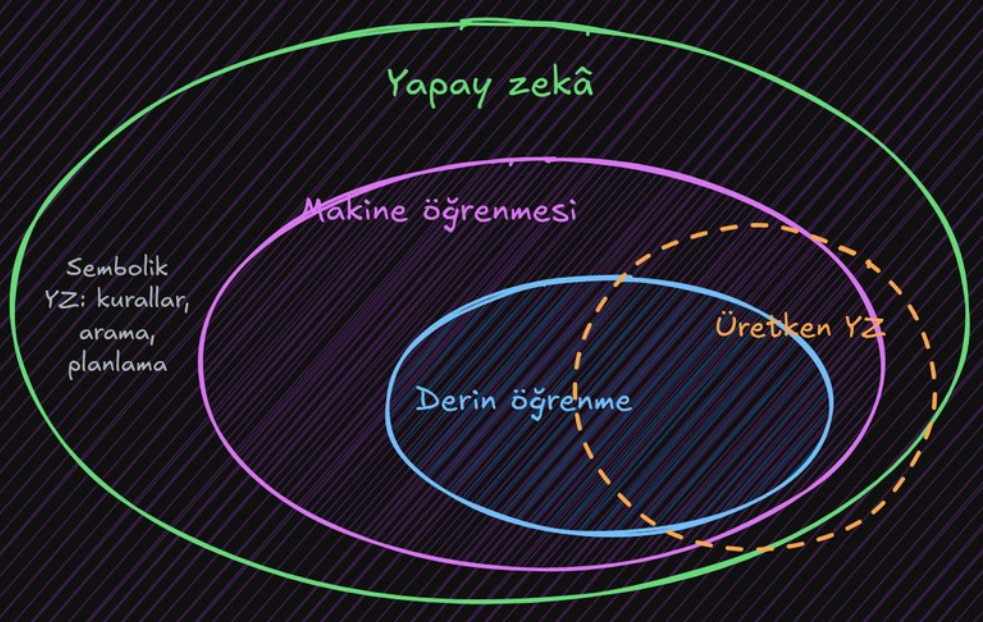

MAKİNE ÖĞRENMESİ

Veriden örüntü çıkararak belirli görev için model oluşturur.

DERİN ÖĞRENME

Çok katmanlı sinir ağlarıyla farklı temsil düzeylerini öğrenir: görüntü, ses, dil.

ÜRETKEN YAPAY ZEKÂ

Yeni metin, görüntü, ses, video veya kod üretir. Çıktı türünü tanımlar; tek bir öğrenme yöntemi değildir.

Derin öğrenme "nasıl yapıldığıyla", üretken yapay zekâ "ne tür çıktı üretildiğiyle" ilgilidir.

6. Yöntem ile yetenek kapsamı ayrı eksenlerdir

Dar yapay zekâ

Belirli görev veya görev kümelerinde çalışan güncel sistemler.

Genel yapay zekâ

İnsanın alanlar arası bilgi aktarımına benzeyen geniş yetenek hedefi.

Süper zekâ

Birçok bilişsel alanda insanı aşan varsayımsal sistemler.

Dar bir sistem sembolik, öğrenen ya da hibrit olabilir.

! Ürün adından yöntemi çıkarmak güvenilir değildir. Aynı ürün birden çok model ve kuralı birleştirebilir; önce "ne yapıyor, neye dayanarak yapıyor?" diye sor.

YBS 319 - Yapay Zekâ ve Öğrenen Algoritmalara Giriş
-Yapay Zekânın Kısa Tarihi-

Alan sekiz düşünce geleneğinden beslendi

01 Felsefe — Doğru çıkarım, bilgi, zihin, eylem

02 Matematik — Mantık, hesaplanabilirlik, olasılık

03 Ekonomi — Tercih, fayda, oyun, karar verme

04 Sinirbilim — Beynin bilgi işleme mekanizmaları

05 Psikoloji — Biliş ve davranışın deneysel modelleri

06 Bilgisayar müh. — Hesaplama makineleri ve altyapı

07 Kontrol kuramı — Geri bildirim, kararlılık, amaçlı davranış

08 Dilbilim — Dil yapısı, anlam ve düşünce

Yapay zekâ yalnızca programlama değildir: bilgiyi, kararı, davranışı ve hesaplamayı birlikte inceleyen disiplinler arası bir alandır.

Kırılma noktaları

1950 Alan Turing — Taklit oyunuyla "düşünme" sorusunu gözlenebilir davranışa çevirdi.

1956 Dartmouth — McCarthy, Minsky, Rochester ve Shannon'ın önerisi; "artificial intelligence" adı.

1956 Logic Theorist — Newell ve Simon: semboller ve sezgisel aramayla teorem kanıtlama.

1958 Perceptron — Rosenblatt: örneklerden ağırlık ayarlayan erken öğrenme modeli.

1970–80 Uzman sistemler — MYCIN, DENDRAL: alan bilgisi kurallar ve çıkarım mekanizmasıyla.

❄ Yapay zekâ kışları — Vaat ile kapasite arasındaki açık; hesaplama, veri ve bakım sınırları.

1986 Geri yayılım — Rumelhart, Hinton, Williams: çok katmanlı ağlarda hata üzerinden ağırlık ayarlama.

1990'lar İstatistiksel MÖ — Olasılıksal yöntemler, SVM, ağaçlar; eğitim/test ile ölçme kültürü.

1997 Deep Blue — Kasparov'u yendi: güçlü arama + değerlendirme işlevi + özel donanım.

2012 AlexNet · ImageNet — Büyük etiketli veri + GPU + derin evrişimli ağ birlikte başarı üretti.

2016 AlphaGo — Öğrenilmiş ağlar + Monte Carlo ağaç araması; Lee Sedol karşısında 4–1.

2017 Transformer — Vaswani ve ekibi: öz dikkat temelli mimari. Mimaridir, ürün adı değildir.

2020'ler Temel modeller · üretken YZ — Geniş veriyle eğitilip farklı görevlere uyarlanan modeller.

Tekrarlayan desen

Büyük vaatlerden gerçek sınırların görülmesine, ardından yeni yöntem, veri ve hesaplama birleşimine uzanan bir döngü.

Kış tek nedenli değildir: aşırı vaat, hesaplama ve veri sınırı, ölçeklenemeyen yöntem, bakım maliyeti ve finansman kararları birlikte etkili oldu.

Güncel yükselişin beş nedeni

Dijital veri — İşlemler, sensörler, metin, görüntü

Hesaplama — GPU, dağıtık sistemler, veri merkezleri

Yöntemler — Temsil öğrenme, dikkat, optimizasyon

Yazılım + bulut — Açık kütüphaneler, API'ler, hazır modeller

Kurumsal talep — Tahmin, kişiselleştirme, karar desteği

Tek bir neden yoktur: yöntemler, onları ölçeklendiren altyapı ve ekonomik kullanım birlikte değişti.

Yöntemsel dersler

* Yapay zekâ tek bir yöntem üzerinden ilerlemedi.
* Sembolik akıl yürütme, öğrenme, arama ve optimizasyon birlikte var olabilir.
* Dar bir gösteri genel zekâ kanıtı değildir (Deep Blue).

Kurumsal dersler

* Aşırı vaat ile gerçek kapasite arasındaki açık güveni ve yatırımı etkiler.
* Bakım, veri, kullanıcı kabulü ve süreç değişimi model kadar belirleyicidir.
* Geçmiş döngüler üretken YZ tartışmalarına ihtiyatlı bakmayı öğretir.

! İsim ezberi yerine fikre odaklan: her kırılma hangi yaklaşımı ya da hangi imkânı değiştirdi?

YBS 319 - Yapay Zekâ ve Öğrenen Algoritmalara Giriş
-Yapay Zekâ Bir Sistemdir: Veriden Karara-

1. Algoritma, model, sistem ve uygulama

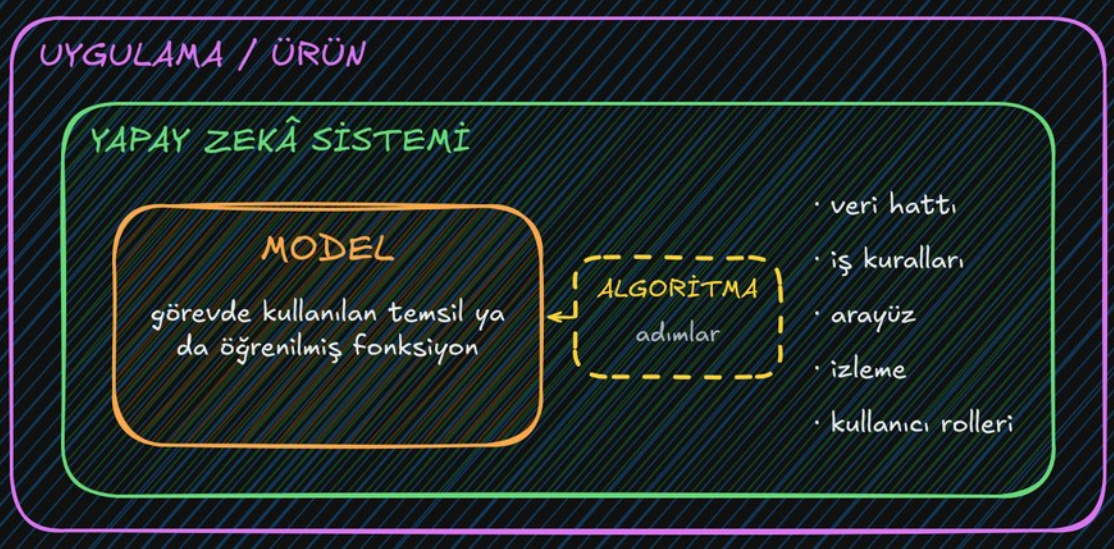

Algoritma: bir problemi çözmek için tanımlanmış adımlar. Karar ağacı algoritması veriden bir ağaç kurar.

Model: kurulan ağacın düğümleri ve eşikleri.

Sistem: model + veri hattı, yazılım, kurallar, arayüz, izleme ve kullanıcı rolleri.

Uygulama: kullanıcının gördüğü, belirli ihtiyacı karşılayan hizmet.

Bir model dosyasını indirmek, çalışan ve yönetilebilir bir yapay zekâ sistemi kurmak anlamına gelmez. Model sistemin motorudur; motor tek başına otomobil değildir.

2. Yapay zekâ sosyoteknik bir sistemdir

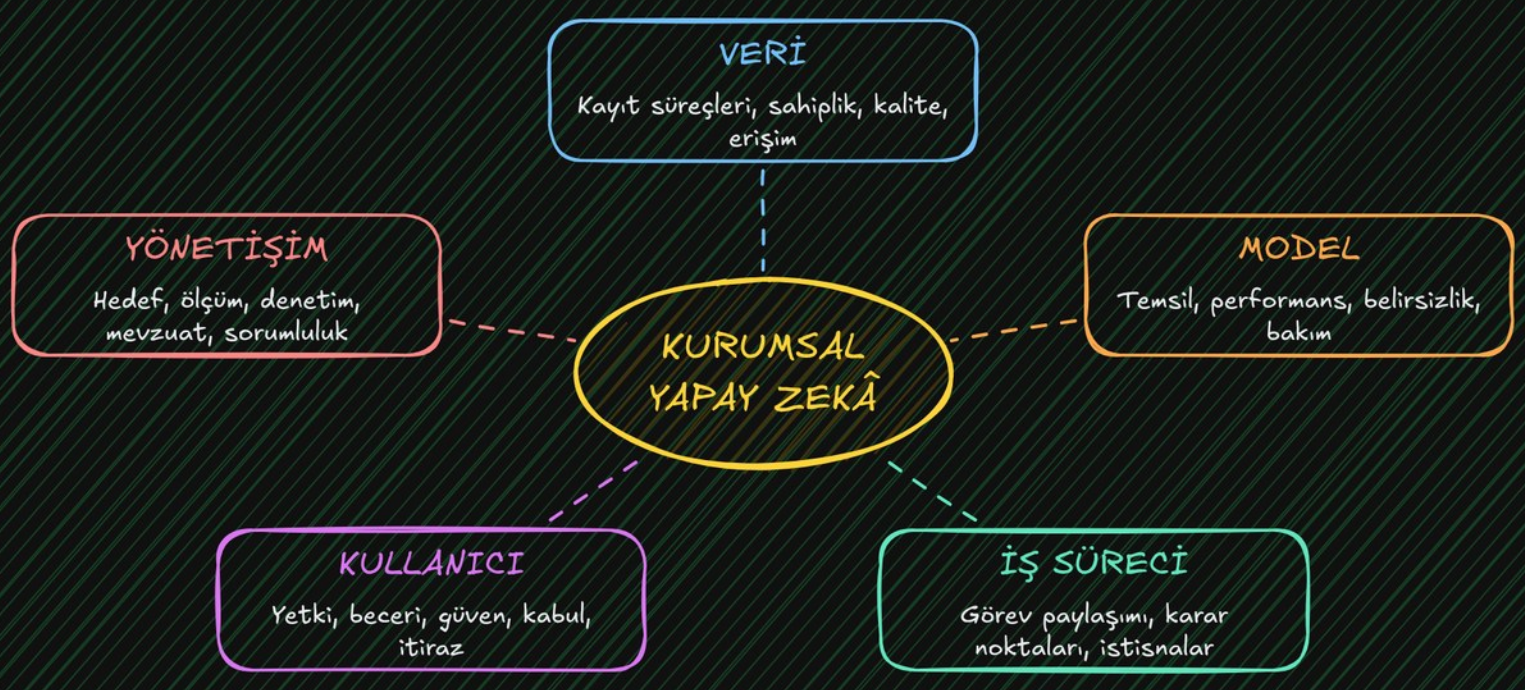

Bir bileşen zayıfsa, teknik olarak güçlü model değer üretmeyebilir ya da kurumsal risk yaratabilir.

3. Veriden karara uzanan zincir

Yapay zekânın değeri veriyi "akıllı" hale getirmesinde değil, belirli bir iş bağlamında daha iyi karar veya eylem üretmesindedir.

4. Karar desteğinden tam otomasyona

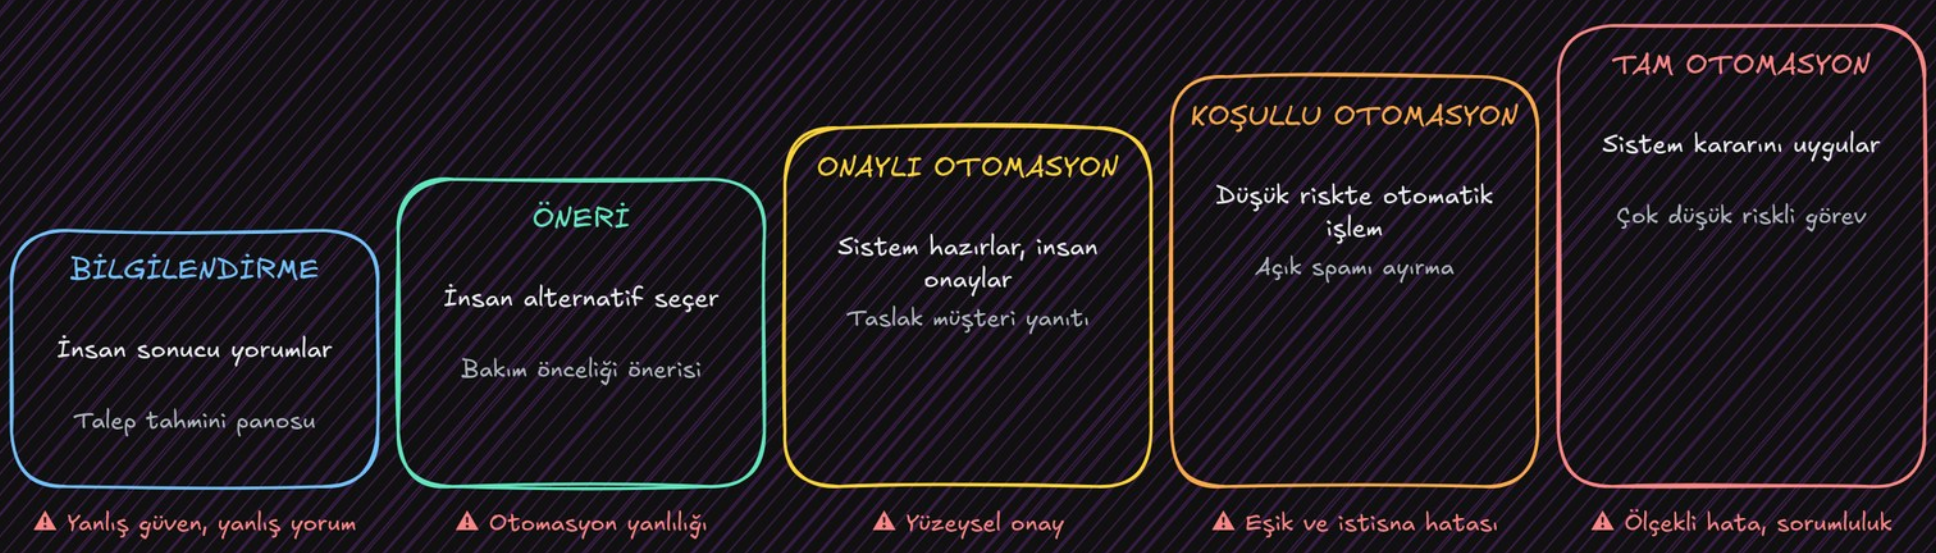

Otomasyon düzeyini kararın geri döndürülebilirliği, etkilenen kişinin hakları ve hata maliyeti belirlemelidir.

5. Yapay zekâ için uygun problem mi?

- ? Karar veya görev açık biçimde tanımlanabiliyor mu?
- ? Başarılı sonuç ölçülebiliyor mu?
- ? Görev sık tekrarlanıyor ya da yüksek değer taşıyor mu?
- ? İlgili ve hukuka uygun veri mevcut mu?
- ? Tahmin iş akışında zamanında kullanılabilir mi?
- ? Yanlış pozitif ve yanlış negatif hataların maliyeti ne?
- ? Daha basit bir kural ya da rapor yeterli olur mu?
- ? İzleme, düzeltme, itiraz ve sorumluluk kurulabilir mi?

Birden çok "hayır" cevabı daha büyük bir model gerektiğini değil, problemin ya da sürecin önce yeniden tasarlanması gerektiğini gösterebilir.

! İyi problem tanımı "yapay zekâ kullanalım" diye başlamaz. Karar kalitesini sınırlayan bilgi ya da süreç eksikliğini belirleyerek başlar.

YBS 319 - Yapay Zekâ ve Öğrenen Algoritmalara Giriş
-Sınırlar ve Güvenilir Yapay Zekâ-

Yapay zekâ ne değildir?

- ✕ **Sihir değildir** — Girdi, hedef, yöntem ve hata koşulları ölçülebilir olmalıdır.
- ✕ **Her karmaşık yazılım değildir** — Karmaşıklık tek başına zekâyla ilişkili görev göstermez.
- ✕ **Her otomasyon değildir** — Sabit iş akışı çıkarım ya da öğrenme içermeyebilir.
- ✕ **İnsan beyninin kopyası değildir** — İşlevsel başarı biyolojik benzerlik gerektirmez.
- ✕ **Bilinç kanıtı değildir** — Birinci tekil kişi ifadeleri iç deneyimi kanıtlamaz.
- ✕ **Her zaman doğru değildir** — Tahmin ve üretim belirsizlik ve hata taşır.
- ✕ **Tarafsız değildir** — Veri, hedef ve kullanım biçimi insan ve kurum tercihleridir.
- ✕ **Her probleme uygun değildir** — Basit kurallar veya süreç düzeltmesi daha iyi olabilir.

Temel sınırlılık türleri

- **Veri bağımlılığı** — Eğitim verisinde bulunmayan koşulları doğal olarak bilmez.
- **Dağılım değişimi** — Kullanım ortamı eğitim döneminden farklılaşabilir.
- **Belirsizlik + hata** — Skor veya olasılık kesin gerçek değildir.
- **Açıklama güçlüğü** — Karmaşık model gerekçesini insan dilinde veremeyebilir.
- **Yanlılık + adalet** — Hata oranları gruplara göre değişebilir.
- **Gizlilik + güvenlik** — Veri sızıntısı, yanıltma ve kötüye kullanım riski.
- **Amaç uyumsuzluğu** — Ölçülen hedef iyileşirken gerçek amaç bozulabilir.
- **İnsan etkenleri** — Otomasyon yanlılığı veya kullanıcı reddi sonucu değiştirir.

Bir riskin önemi bağlama bağlıdır: sağlık, kredi ve eğlence önerisi aynı hata maliyetine sahip değildir.

Güvenilir yapay zekâ için NIST çerçevesi

Bu özellikler arasında gerilim olabilir. Risk yönetimi hepsini aynı anda en üst düzeye çıkarmak değil, bağlama göre dengelemektir.

Teknik performans ≠ işletme değeri

Teknik performans

* Doğruluk, hata, sıralama kalitesi veya maliyet ölçülebilir.
* Test başarısı modelin belirli koşullardaki performansını gösterir.
* Sınıf dağılımı ve hata türleri tek bir doğruluk oranını yanıltıcı kılabilir.
* Kullanım ortamı değiştikçe performans bozulabilir.

İşletme değeri

* Gelir artışı, maliyet azalması, süre kısalması, kalite ya da risk azalması.
* Çıktının zamanında doğru kişiye ulaşması gerekir.
* Kullanıcı benimsemesi ve süreç tasarımı teknik skoru değere dönüştürür.
* Değer ölçülmüyorsa katkı bilinmez.

Bir sistemi değerlendirmek için dokuz soru

1. Sistem hangi somut amacı ve kimin amacını izliyor?
2. Girdi verisi nasıl üretildi, kimi temsil etmiyor?
3. Model hangi ortamda eğitildi, nerede kullanılacak?
4. Çıktı tahmin mi, öneri mi, karar mı, içerik mi?
5. Başarı hangi ölçüt ve karşılaştırmayla değerlendirildi?
6. Yanlış sonuçtan kim, nasıl etkileniyor?
7. Kullanıcı sonucu anlayabilir, düzeltebilir, itiraz edebilir mi?
8. Performans ve etkiler kullanım sonrasında izlenecek mi?
9. Sağlayıcı değişirse ya da sistem kapanırsa süreç çalışır mı?

! Sorumluluk modelde değil; amaçları, veriyi, yetkileri ve kullanım koşullarını belirleyen insan ve kurumlarda kalır.

YBS 319 - Yapay Zekâ ve Öğrenen Algoritmalara Giriş
-Makine Öğrenmesi Problemini Tanımlamak-

Makine Öğrenmesi Nedir?

Bir program, T görevlerinde P ile ölçülen performansı E deneyimiyle artıyorsa öğreniyordur.
(Tom Mitchell, 1997)

T Görev
Gelecek haftanın ürün talebini tahmin etmek

E Deneyim
Geçmiş satış, takvim ve kampanya kayıtları

P Başarı ölçütü
Görülmemiş haftalarda tahmin hatası

1. Bir satır neyi temsil ediyor?

Özellikler (girdiler)					Hedef (etiket)
Mağaza	Ürün	Hafta	Fiyat	Kampanya	Sonraki hafta satış
A	Su	36	18 TL	Evet	142
A	Su	37	18 TL	Hayır	119
B	Süt	36	31 TL	Evet	76

Bir satır = bir örnek (gözlem). Burada birim: mağaza-ürün-hafta.

Satır birimi değişince (müşteri, sipariş, mağaza-gün) öğrenme görevi de değişir.

* Girdiler karar anında bilinir; son sütun geçmiş örnekler için öğrenme hedefidir.
* Etiket yalnızca sınıf adı değildir: sayısal hedef de denetimli öğrenmede hedeftir.

2. Aynı veri, iki görev: fark hedefin türüdür.

Sınıflandırma

Hedef bir kategori.

"Gelecek 7 günde stok tükenir mi?"

→ Evet / Hayır

İkiden fazla sınıf (düşük / orta / yüksek risk) → çok sınıflı sınıflandırma

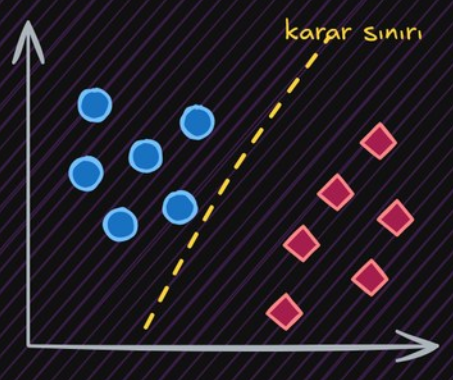

Regresyon

Hedef sayısal bir miktar.

"Gelecek hafta kaç adet satılır?"

→ 142, 119, 76 ...

Diğer örnekler: teslim süresi, fiyat, enerji tüketimi

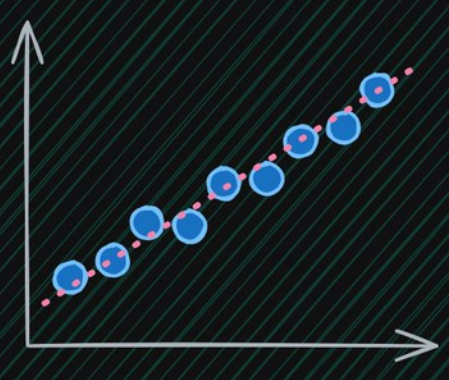

3. Bir skor kararın kendisi değildir

Model (öğrenilmiş ilişki) → Tahmin ("%70 stok tükenme olasılığı") → Eşik / iş kuralı (ör. olasılık ≥ %60 ise) → Karar (sipariş ver)

Eşik seçimi, yanlış alarm ile kaçırılan olay arasındaki dengeyi belirler. Teslim süresi ve stok maliyeti de kararı değiştirir.

Eşiği değiştirmek tahmini değiştirmez; yalnızca kararı değiştirir.

4. Öğrenme sinyali nereden geliyor?

Denetimli

Girdiler + geçmiş doğru sonuçlar (hedef) var.

"Denetim": hedef değerinin varlığı; birinin her adımı izlemesi değil.

Denetimsiz

Girdiler var, doğru cevap sütunu yok.

Gruplama, boyut azaltma, aykırılık arama. Gruplar kendiliğinden iş etiketi değildir.

Yarı denetimli

Az sayıda etiketli + çok sayıda etiketsiz örnek.

Örn. uzmanlar iade nedenlerinin yalnızca bir kısmını kodlamış.

Pekiştirmeli

Ajan ortamı gözler, eylem seçer, ödül veya maliyet görür.

Tek doğru cevap yerine eylem–sonuç dizisinden öğrenir.

5. Eğitim başarısı yetmez: genelleme

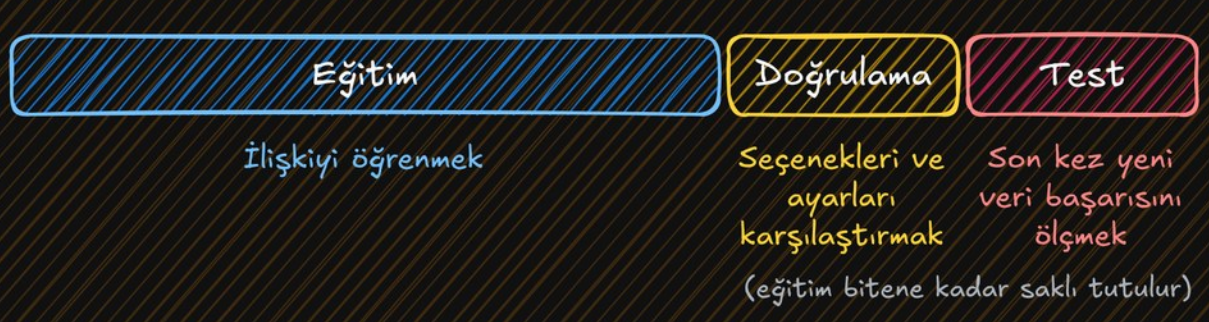

İlişkiyi öğrenmek

Seçenekleri ve ayarları karşılaştırmak

Son kez yeni veri başarısını ölçmek

(eğitim bitene kadar saklı tutulur)

! Teste defalarca bakıp tasarımı ona göre değiştirirsek test de dolaylı olarak eğitim sürecine karışır.

Aşırı uyum

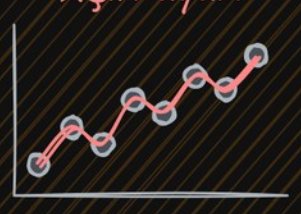

Eğitim iyi, yeni veri zayıf

Yetersiz uyum

Eğitim ve yeni veri birlikte zayıf

Hedef: yeni örneklerde tutarlı başarı.

6. Veri sızıntısı

Modelin gerçek kullanımda erişemeyeceği bilgiyi eğitim veya değerlendirme sırasında görmesidir. Test başarısı yanıltıcı biçimde yükselir.

Sızıntı yalnızca gelecek sütunuyla olmaz: temizleme, ölçekleme veya seçim kurallarını tüm veriden (test dahil) öğrenmek de test bilgisini taşır.

! Her özellik için sor: "Bu değeri karar anında gerçekten biliyor muyuz?" Etiket yanlış, eksik ya da iş amacının yalnızca bir vekiliyse, model yüksek test başarısıyla bile yanlış soruya iyi cevap verebilir.

YBS 319 - Yapay Zekâ ve Öğrenen Algoritmalara Giriş
-Güvenilir Bir Öğrenme Çalışması-

Bir makine öğrenmesi çalışmasının akışı

1. Çerçeve — Görevi, hedefi ve kullanım anını tanımla

→ **2. Veri** — Kaynakları, kaliteyi ve temsil sorununu incele

→ **3. Değerlendirme** — Eğitim, doğrulama ve testi ayır

→ **4. Kullanım** — Sonucu işe bağla, değişimi izle

izleme sonucu çerçeveye geri döner

Bu akış algoritma seçimini merkeze koymaz: önce problem, veri ve değerlendirme kurulur.

Neden makine öğrenmesi?

* Kuralları yazmak zor: spam dilindeki yeni kalıplar, binlerce ürünün talep örüntüsü
* Koşullar değişiyor: mevsim, kampanya, yeni müşteri davranışı
* Veride ilişki var: tahmin üretmek, analize yardımcı örüntü bulmak

"Veri varsa ML kullanırız" doğru değildir; açık kuralla ucuz ve güvenilir çözülen görevde model ek karmaşıklık yaratır.

Problem öğrenmeye uygun mu?

* 01 · Tekrarlanan ve ölçülebilir bir görev var mı?
* 02 · Örnekler kullanım koşullarını temsil ediyor mu?
* 03 · Gerekli girdiler karar anında elde mi?
* 04 · Hata maliyeti ve insan denetimi baştan belli mi?

Yeni mağaza açılışı gibi kaydı olmayan durumda aynı güveni bekleyemeyiz.

Hedef tanımı öğrenmeyi yönlendirir

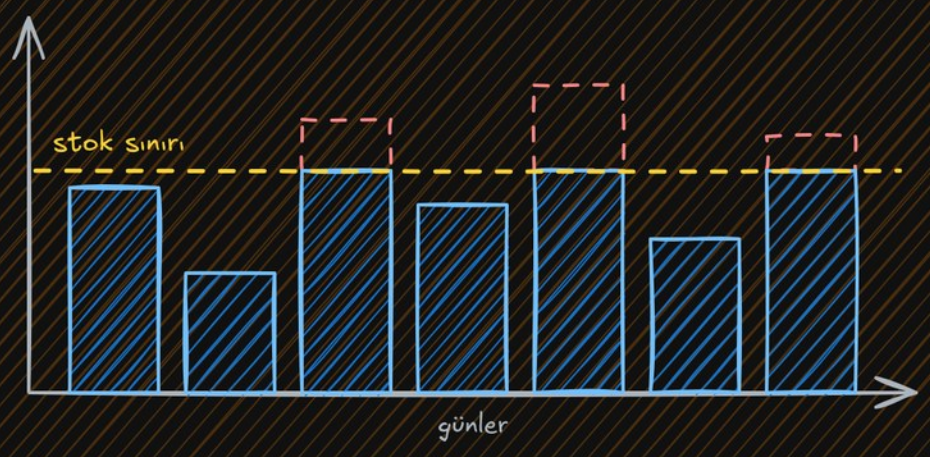

"Satılan adet" ile "gerçek talep" aynı değişken olmayabilir.

Stok biterse gerçekleşen satış sınıra takılır: kırmızı kesikli kısım gözlenmemiş talep.

İadeler, iptaller ve kayıt gecikmesi de sonucu değiştirebilir.

Etiketin nasıl üretildiği belgelenmelidir.

Öğrenme biçimi: iki ayrı soru

Toplu öğrenme
* Veri biriktirilir
* Model belirli aralıklarla yeniden eğitilir
* Yeni sürüm testten sonra kullanılır

Çevrim içi öğrenme
* Yeni örnekler adım adım işlenir
* Model daha sık güncellenir
* Bozuk veri etkisi hızla yayılabilir

Örnek temelli
* Yeni vakayı benzer geçmiş vakalarla karşılaştırır
* Benzerliğin nasıl tanımlandığı kritiktir

Model temelli
* Geçmiş örneklerden bir ilişki kurar
* Yeni girdiye öğrenilmiş ilişkiyi uygular

"Her gün tahmin yapıyor" ifadesi modelin her gün yeniden öğrendiğini kanıtlamaz. Bu ayrımlar denetimli/denetimsiz ayrımından bağımsızdır.

Genelleme ve temsil edici veri

Modelin değeri, görmediği örneklerdeki başarısıdır. Eğitim başarısı yalnızca başlangıç bilgisidir.

* Eksik kapsam: yalnız büyük mağazalar, yalnız normal satış haftaları.
* Sonuç: yeni bölgede hata artabilir; ortalama başarı alt grubu gizleyebilir.
* Kontrol: kullanım kitlesini tanımla, dönem ve alt gruplarda ayrı değerlendir.

Aynı dar gruptan daha fazla satır eklemek temsil sorununu çözmez.

Basit başlangıç düzeyi

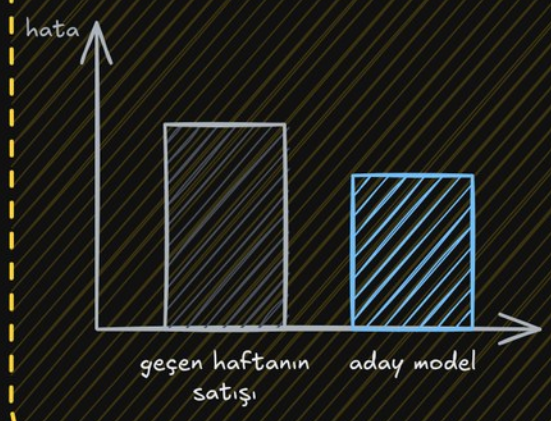

Model, kolay bir kıyaslamayı geçmeden "başarılı" sayılmaz.

Aynı test dönemi ve aynı hata ölçüsüyle karşılaştır.

Fark, veri ve bakım maliyetini karşılıyor mu?

Kullanımda model neden eskir?

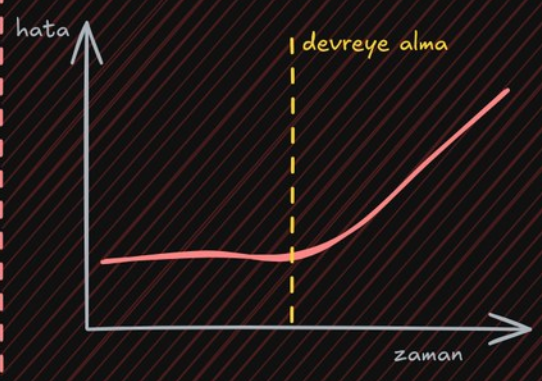

* Dünya değişir: fiyat, rakip, mevsim, alışkanlık.
* Kayıt değişir: yeni POS, ürün kodu, tanım farkı.
* Hata ve alt grup performansını izle; gerekirse veri, hedef ve modeli gözden geçir.

! Bir performans iddiasını duyduğunda sor: Hangi dönemde, hangi mağazalarda, hangi ürünlerde ve neye kıyasla ölçüldü?

YBS 319 - Yapay Zekâ ve Öğrenen Algoritmalara Giriş
-Keşifsel Veri Analizi (Titanic)-

Keşifsel veri analizinin amacı

Amaç bir tahmin modeli kurmak değil; veriyi okumak, yapısını ve sorunlarını görmek, uygun özetler ve grafikler üretmek ve bulguları dikkatle yorumlamaktır.

KVA sorunu ve bağlamını anlamamızı sağlar. Sorunları nasıl çözeceğimiz veri ön işlemenin konusudur.

1. Veriyi tanı

891 satır (yolcu) · 12 sütun · tekrarlanan kayıt: 0

Veri tipi değerin nasıl saklandığını, ölçüm türü neyi ifade ettiğini söyler: Pclass tam sayıdır ama bir kategoridir.

Eksik değer oranı

NaN sıfır ya da "kabin yok" değildir; kayıtlı değerin eksik olduğunu gösterir.

2. Dağılımlara bak

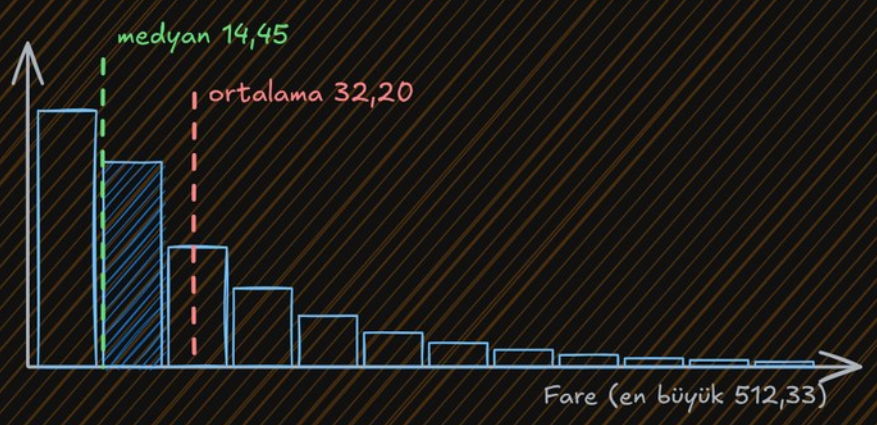

Ortalama medyandan çok yüksek → sağa çarpık. Yalnızca ortalama kullanmak tipik yolcuyu olduğundan yüksek ücretli gösterir.

Age: ortalama 29,70 · medyan 28 · aralık 0,42–80 (yalnızca 714 yolcu)

3. Gruplar eşit büyüklükte değilse sayıyı değil oranı karşılaştır

Üçüncü sınıfta hayatta kalan sayısı (119) ikinci sınıftakinden (87) fazla, ama oranı yarısı kadar.

Hedef: 549 kişi (%61,6) hayatta kalmadı, 342 kişi (%38,4) kaldı.

Female %74,2 · Male %18,9 → fark 55,3 yüzde puan. Yüzde puan ile yüzde değişimi aynı kavram değildir.

Küçük gruplarda oran daha oynaktır: Q limanı yalnızca 77 kişi, 61+ yaş yalnızca 22 kayıt.

4. Soruya uygun grafiği seç

Histogram

Tek sayısal değişkenin şekli (Age, Fare)

Kutu grafiği

Çeyrekler, uçlar; gruplara göre karşılaştırma

Sütun grafiği

Kategorilerin sayısı veya oranı (Pclass)

Saçılım grafiği

İki sayısal değişkenin birlikte değişimi

Histogram aralıklarının (bins) sayısı görünümü değiştirir; alttaki veriyi değiştirmez.

5. Değişkenleri birlikte incele

Hayatta kalma	1. sınıf	2. sınıf	3. sınıf
Female	%96,8	%92,1	%50,0
Male	%36,9	%15,7	%13,5

Hem cinsiyet içinde sınıf farkı hem sınıf içinde cinsiyet farkı görülüyor. Bu ayrıştırma nedensellik anlamına gelmez.

Ücret ile sonuç arasındaki farkın bir bölümü sınıf bileşiminden kaynaklanıyor olabilir (medyan Fare: 60,29 · 14,25 · 8,05).

6. Eksiklik gruplara göre farklı mı?

	1. sınıf	2. sınıf	3. sınıf
Age eksik	%13,9	%6,0	%27,7
Cabin eksik	%18,5	%91,3	%97,6

Yaşı eksik kişileri silmek üçüncü sınıfı görece daha fazla dışarıda bırakır.

Kabin kodu bilinenler üzerinden tüm sınıflara çıkarım yapmak ciddi seçilim yanlılığı yaratabilir.

7. Korelasyonu dikkatle oku

* Pclass kodu büyüdükçe üçüncü sınıfa gidilir; negatif işareti bu bağlamda okunur.
* Fare ile Pclass güçlü ilişkili: ikisini bağımsız kanıtlar gibi yorumlama.
* Küçük korelasyon "ilişki yok" demek değildir; ilişki doğrusal olmayabilir.

! KVA hipotez üretir, nedensellik kanıtlamaz. Her bulguda sor: Bu fark başka bir değişkenin (sınıf, yaş, cinsiyet) bileşiminden kaynaklanıyor olabilir mi?

YBS 319 - Yapay Zekâ ve Öğrenen Algoritmalara Giriş
-Veri Kalitesi ve Eksik Veri-

Veri ön işleme nedir?

Keşifsel analizde belirlenen sorunların ele alınması ve verinin modellemeye hazırlanmasıdır.

KVA'nın sorusu

"Yaş hangi yolcularda eksik? Yüksek ücretler hangi sınıflarda yoğun?"

Ön işlemenin sorusu

"Yaşı eksik yolcuları silmeli miyiz, doldurmalı mıyız? Ücreti dönüştürecek miyiz?"

Ham veri → Kalite kontrolü → Veri ayrımı → Hazırlama → Doğrulama

Yöntemi seçerken sor: Neyi düzeltmek istiyoruz? Ne kaybedebiliriz? Başarıyı nasıl kontrol edeceğiz?

1. Kalite kontrol listesi

* Şema: beklenen sütunlar var mı? Sayısal sütunda metin var mı?
* Geçerli değer: Survived ∈ {0,1}, Pclass ∈ {1,2,3}; yaş ve ücret negatif değil mi?
* Kategori tutarlılığı: "male", "Male", " male " aynı etiket mi?
* Eksik değer temsili: boş hücre, "?", "unknown", -999 aynı anlamda mı?
* Mantıksal tutarlılık: kimlik benzersiz mi, sayımlar tam sayı mı?

Age = 0,42 bir bebeğin yaşı olabilir; Fare = 0 değerini kaynağa bakmadan hatalı sayma.

2. Yinelenen kayıtlar

Aynı gözlemin yanlışlıkla birden fazla kaydedilmesidir. Önce satırın birimini bil: Titanic'te bir satır bir yolcudur.

Tam satır	Bütün alanlar aynı mı? Tekrarlı yükleme ihtimalini araştır.
Kimlik	PassengerId tekrar ediyor mu? Aynı kayıt mı, çelişen kayıt mı?
Seçilmiş alan	İsim, bilet aynı mı? Alan bilgisi olmadan otomatik silme.

Ortak bilet kodu, iki satırın aynı yolcu olduğunu göstermez: aile üyeleri aynı biletle seyahat etmiş olabilir.

3. Eksik değer: neden kayıp?

Eksik değer, gözlemin bir alanının kayıtlı olmamasıdır; sıfır, "hayır" ya da "kabin yok" ile aynı değildir. Titanic'te Cabin 687, Age 177, Embarked 2 gözlemde eksik.

MCAR

Tamamen rastgele

Eksiklik gözlenen ve gözlenmeyen değerlerden bağımsız.

Örn. Formlar aktarımda rastgele kaybolmuş.

MAR

Gözlenen bir alana bağlı

Gözlenen alanlar hesaba katılınca eksik değerin kendisine bağlı değil.

Örn. Üçüncü sınıfta yaş daha sık eksik.

MNAR

Gözlenmeyen değere bağlı

Eksiklik, eksik değerin kendisi veya gözlenmeyen etkenlerle bağlantılı.

Örn. Yaşı çok yüksek kişiler yaşını paylaşmıyor.

Eksiklik gözlenen bir alanla ilişkiliyse MCAR varsayımını sorgularız. Ama kayıp değerleri görmediğimiz için MAR ile MNAR ayrımı tablodan kesin olarak yapılamaz: kayıt sürecini araştır.

4. Silme mi, doldurma mı?

	Ne zaman düşünülür?	Sınırı
Satır silme	Az kayıt eksikse ve silmenin etkisi incelendiyse	Örneklem ve alt grup temsili azalabilir.
Sütun çıkarma	Çok eksik ve ek bilgi sağlamayan alan	Değerli kısmi bilgi kaybolabilir.
Ortalama / medyan	Sayısal alanlar için basit başlangıç	Varyansı ve ilişkileri değiştirir; medyan uçlara daha dayanıklı.
Mod / "Bilinmiyor"	Kategorik alanlar	Mod en sık kategoriyi şişirir; "Bilinmiyor" ayrı anlam taşır.
Grup bazlı	Anlamlı gruplar varsa (ör. Pclass medyanı)	Az gözlemli gruplar için genel eğitim medyanı yedek.
KNN / çok değişkenli	Diğer alanlarda yararlı benzerlik varsa	Ölçeğe duyarlı; tek tahmin belirsizliği gizler.

Yüzde tek başına karar eşiği değildir: %1 kayıp küçük bir grubun tamamını silebilir. Sütun eksik oranı, satır kaybı ve alt grup oranlarını ayrı hesapla.

Eksiklik göstergesi

YasEksik = Age.isna() sütununu doldurmadan önce üret: sonradan doldurulan yaşın başlangıçta bilinmediği korunur.

KabinBilgisiVar, kabin bilgisinin kaydedilip kaydedilmediğini gösterir; yolcunun kabini olup olmadığını değil.

Doldurma ve sızıntı

Doldurma değerini (medyan, mod) yalnızca eğitim verisinden öğren; test aynı değerle doldurulur.

× Eksik yaşı Survived gruplarına göre doldurmak hedef sızıntısıdır: yeni yolcunun sonucunu bilmiyoruz.

! Doldurma bütün gözlemleri tutar ama eksik bilginin tamamını geri getirmez. Doldurulan değer gözlenmiş gerçek değer değildir; hangi değeri neden ürettiğini kaydet.

YBS 319 - Yapay Zekâ ve Öğrenen Algoritmalara Giriş
-Hatalı ve Aykırı Değerler-

Hatalı değer

Ölçüm veya kayıt kurallarını ihlal eder.

Yaş 250 · negatif ücret · yanlış para birimi · kaymış ondalık ayıracı

Aykırı değer

Diğer gözlemlerden belirgin biçimde uzaktır, ama doğru olabilir.

Titanic'te yüksek bilet ücretleri birinci sınıfın gerçek özelliği olabilir.

1. Çeyrekler arası açıklık (IQR)

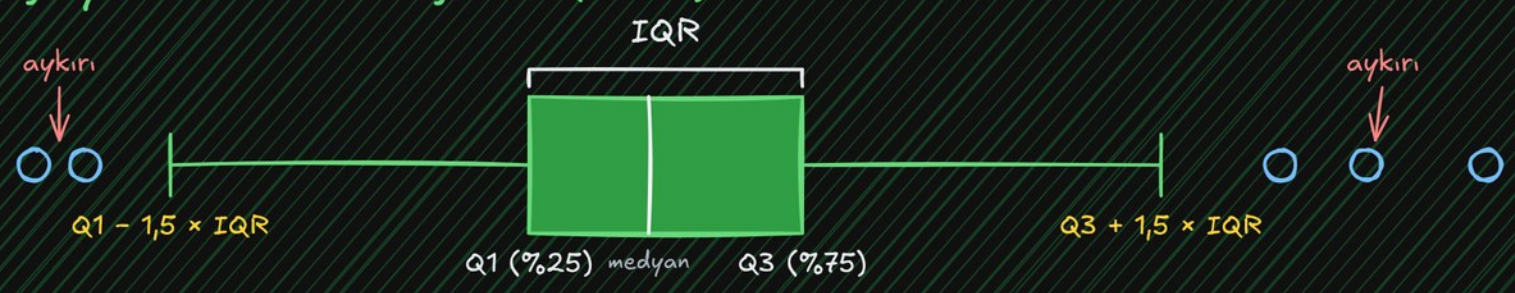

$IQR = Q3 - Q1$

Yaygın seçim k = 1,5; bu katsayı bir değerin hatalı olduğunu tek başına göstermez.

Titanic Fare:	Q1	Q3	IQR	üst eşik	eşik üstü	en büyük
	7,91	31,00	23,09	65,63	116 kayıt	512,33

116 kaydı "hatalı" deyip silmek gerçek yüksek ücretli yolcuları ve sınıf dağılımını bozar. Çeyrek kuralı bir alarmdır, veri temizleme kararı değildir.

2. Z-skoru

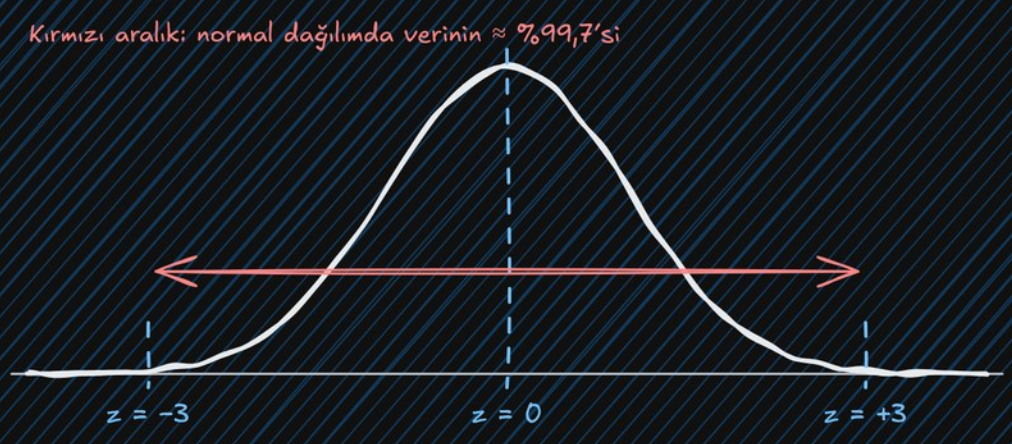

$z = (x - \text{eğitim ortalaması}) / \text{eğitim standart sapması}$

İnceleme işareti: $|z| >$ eşik (yaygın başlangıç: 3).

Çarpık dağılımda uzun kuyruk ortalamayı ve standart sapmayı büyütür; bazı uç değerler gizlenebilir (maskeleme).

Normal dağılımın ±3 yorumu her dağılıma taşınamaz. 1,5 × IQR ile $|z| > 3$ eşdeğer kurallar değildir.

3. Hangi yöntem ne zaman?

Z-skoru

Yaklaşık normal, tek tepeli, simetrik dağılım.

Uçlar ortalama/sapmayı bozabilir.

IQR

Çarpık, uzun kuyruklu, belirgin uç değerli alan.

Normal dağılım gerektirmez; çok çarpık veride fazla işaretleyebilir.

MAD tabanlı Z

Uçlardan az etkilenen merkez ve yayılım gerektiğinde.

Medyan ve medyan mutlak sapma kullanır.

Grup / çok değişkenli

Karışık gruplar, çok tepeli veri, sıra dışı değer birleşimleri.

Bütün yolcularda yüksek ücret, birinci sınıf içinde olağan olabilir.

4. Aykırılığın üç nedeni

Kayıt / ölçüm hatası

Yaş 250, yanlış para birimi, kaymış ondalık.

→ Kaynaktan doğru değeri araştır. Düzeltilemezse hatalı hücreyi eksik olarak ele al.

Geçerli nadir gözlem

Çok yüksek ücret ödeyen gerçek birinci sınıf yolcusu.

→ Otomatik silme yerine koruma, dönüşüm veya dayanıklı yöntem.

Farklı süreç / kapsam

Yolcu tablosuna personel kaydının karışması.

→ Analiz evrenini tanımla; kapsam dışı doğrulanırsa ayrı tut.

5. Ne zaman sileriz, ne zaman doldururuz?

Önce doğrula: hata mı, nadir gözlem mi, kapsam dışı mı?

Doğru değeri biliyorum	Düzelt (250 → 25). Tahminle düzeltme yapma.
Yalnız bir hücre hatalı, doğru değer yok	Hücreyi eksik işaretle, eksik veri süreciyle doldur; yolcunun diğer bilgileri korunur.
Kayıt bütünüyle güvenilmez, tekrar ya da kapsam dışı	Satır çıkarmayı düşün; kuralı, sayıyı ve alt gruplara etkiyi kaydet.
Değer gerçek	Sırf eşik dışı diye medyanla değiştirme: koru, log, dayanıklı ölçekleme.

Kırpma değeri sınıra taşır · winsorization seçilen yüzdeliklere taşır · trimming gözlemi çıkarır. Sınırlar eğitimden öğrenilir.

! Testte zor yolcuları silip puanı yükseltmek çözüm değildir: model daha sonra karşılaşacağı yolcularla değerlendirme verisinde de karşılaşmalıdır.

YBS 319 - Yapay Zekâ ve Öğrenen Algoritmalara Giriş
-Kodlama, Dönüşüm ve Ölçekleme-

1. Kategorik kodlama

Birçok algoritma sayısal girdi bekler. Kategorileri sayıya çevirirken gerçekte olmayan bir sıra ya da uzaklık yaratmamalıyız.

× Sayı etiketi vermek

C	→	0
Q	→	1
S	→	2

Model "S > Q > C" ya da "Q, C ile S'nin ortasında" gibi sahte bir ilişki görebilir.

✓ One-Hot Encoding

Liman	C	Q	S
C	1	0	0
Q	0	1	0
S	0	0	1

Her kategori için bir gösterge sütunu; sıra varsaymaz.

Nominal (sırasız: Sex, Embarked) → One-Hot

Ordinal (sıralı) → OrdinalEncoder; ama sıra, kategoriler arası mesafenin eşit olduğunu garanti etmez.

Pclass için ordinal kod ya da one-hot: bir modelleme tercihi.

LabelEncoder hedef etiketleri içindir; girdi sütunlarında kullanılmaz.

Kategori sözlüğü eğitimde öğrenilir. Eğitimde görülmeyen liman: handle_unknown="ignore" → sıfır vektörü.

2. Dağılım dönüşümü: log1p

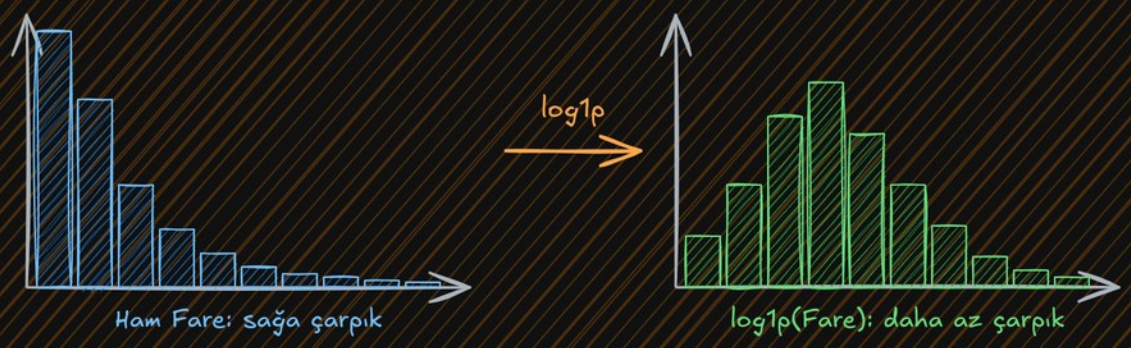

$\log1p(x) = \ln(1 + x)$

$0 \to 0 \cdot 10 \to 2{,}40 \cdot 100 \to 4{,}62 \cdot 1000 \to 6{,}91$

Büyük değerler arasındaki farkı daha çok sıkıştırır; sıfırı korur, sırayı korur.

Yüksek ücretleri silmek yerine log1p seçiyoruz. Ama dönüşüm hata düzeltmez: negatif ücret log ile geçerli olmaz.

Geçerlilik kontrolü → Eksik doldurma → Seçilen alanda log → Ölçekleme

0/1 göstergelere ve nominal kategorilere dağılım dönüşümü uygulamak anlamlı değildir. Yaşa sırf sayısal diye log uygulamayız.

3. Ölçeklendirme

Uzaklık ya da ceza kullanan yöntemlerde büyük sayısal aralıklı özellik, yalnızca birimi nedeniyle baskın hâle gelebilir.

İlk iki yolcu: Age 22 ve 38 · Fare 7,25 ve 71,28

ücret farkı² ≈ 4100 → uzaklığın ≈ %94,1'i

yaş farkı² = 256

StandardScaler

$(x - \mu) / \sigma$

Eğitimde ortalama ≈ 0, varyans ≈ 1. Uçlardan etkilenir.

MinMaxScaler

$(x - \min) / (\text{maks} - \min)$

Eğitim aralığı [0, 1]. Uç değerlere duyarlı.

RobustScaler

$(x - \text{medyan}) / \text{IQR}$

Medyan ve çeyrekleri kullanır; uçları silmez.

KNN / K-Means	SVM (RBF)	Düzenlileştirilmiş doğrusal	PCA	Sinir ağı	Karar ağacı / RF
ölçeğe duyarlı: uzaklık	ölçeğe duyarlı: çekirdek uzaklığı	ölçeğe duyarlı: ceza	ölçeğe duyarlı: varyans	ölçeğe duyarlı: optimizasyon	genellikle gerekmez: bölmeler sıraya dayanır

Ölçekleme birim etkisini azaltır; değişkenleri eşit derecede önemli yapmaz.

Elle hesap

Yaş ort. 30, sapma 10; yaş = 40
(40 − 30) / 10 = 1 · Ortalamanın bir sapma üzerinde

Ücret min 0, maks 500; ücret = 100
100 / 500 = 0,20 · Eğitim aralığında beşte bir konum

Aynı parametreler; yeni ücret = 750
750 / 500 = 1,50 · Maksimumu aşar: testte yeni fit yapılmaz

Ne değişir, ne değişmez?

	MinMax	Standard	log1p
Çarpıklık şekli	korunur	korunur	değişebilir
Sabit aralık	[0,1] eğitimde	yok	yok
Sıra	korunur	korunur	korunur

MinMax ve Standard alternatiftir; log → Standard ise farklı işlevleri birleştirir.

! StandardScaler veriyi normal dağılıma dönüştürmez; yalnızca merkezi ve ölçeği değiştirir. Ölçekleme parametreleri eğitimde fit edilir, test aynı parametrelerle transform edilir.

YBS 319 - Yapay Zekâ ve Öğrenen Algoritmalara Giriş
-Özellik Mühendisliği, Sızıntı ve Pipeline-

1. Özellik mühendisliği

Mevcut alanlardan probleme uygun temsiller üretmektir. Yeni sütunun nasıl hesaplandığı ve neyi ifade ettiği açıkça yazılır.

SibSp 1 + Parch 2 + kendisi 1 = AileBuyuklugu 4

TekYolcu	AileBuyuklugu == 1
Unvan	Name içinden Mr, Mrs, Miss...
Guverte	Cabin kodunun güverte bölümü
KabinBilgisiVar	Cabin değeri dolu mu?
YasGrubu	Önceden belirlenen yaş aralıkları

Bir özelliğin hesaplanabilmesi, tahmin anında kullanılabileceğini göstermez. Aralıklara ayırmak yorumu kolaylaştırır ama aralık içindeki ayrıntı kaybolur.

2. Öznitelik seçimi ve boyut indirgeme

Alan bilgisi
PassengerId'yi girdiden çıkar; ham Name yerine unvanı değerlendir.

Filtre
Sabit / düşük varyanslı, yüksek ilişkili sütunlar; hedefle ilişki ölçüleri.

Sarmalayıcı
Alt kümeleri model ve eğitim içi doğrulamayla karşılaştır; pahalı olabilir.

Model tabanlı
Düzenlileştirme veya ağaç önemleri; önemler yönteme bağlıdır.

× Survived ile Pearson korelasyonu düşük diye Age'i otomatik eleme: ilişki doğrusal olmayabilir, etkileşim ve eksiklik sonucu etkiler. Seçim test sonuçlarına bakılarak yapılmaz.

PCA, varyansı en çok açıklayan doğrusal yönleri hedefi kullanmadan bulur. En çok varyans taşıyan bileşen, hedef için en yararlı olmayabilir. Titanic'te zorunlu değil.

3. Veri ayrımı ve sızıntı: fit yalnızca eğitimde

Veri sızıntısı, değerlendirmede bilinmemesi gereken bilginin eğitim sürecine ulaşmasıdır. Survived'ı X'e eklemek belirgin bir örnek; bütün veriden medyan veya ölçek hesaplamak daha gizli bir örnektir.

Öğrenilen işlemler
Medyan, mod, kategori sözlüğü, ölçekleme istatistikleri, IQR sınırları, PCA bileşenleri, model tabanlı seçim → eğitimden öğrenilir.

Sabit kurallar
Boşluk temizliği veya SibSp + Parch + 1 gibi satır bazlı formüller → veri dağılımından parametre öğrenmez.

fit	Parametreleri öğren (medyan, ölçek, kategoriler...)	Yalnızca eğitim ya da ilgili eğitim katı
transform	Öğrenilmiş parametrelerle dönüştür	Eğitim, doğrulama, test ve yeni veri
fit_transform	Öğren ve aynı eğitim verisini dönüştür	Yalnızca eğitimde; testte kullanılmaz

Çapraz doğrulamada doldurucu ve ölçekleyici her katta yalnızca o katın eğitim bölümünde öğrenilir. stratify=y hedef oranlarını bölümler arasında yaklaşık korur.

4. Tekrarlanabilir hat: Pipeline + ColumnTransformer

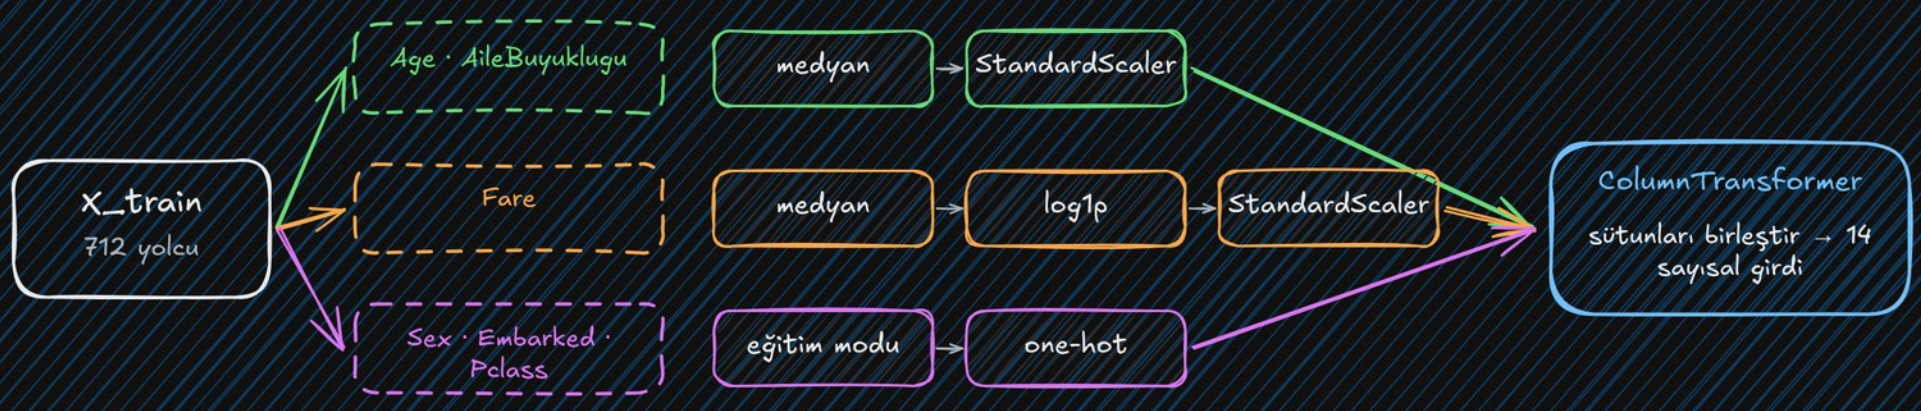

Aynı öğrenilmiş hat doğrulama, test ve yeni yolcuya uygulanır: X_test için transform(X_test). Pipeline sızıntıyı önlemeye yardım eder, ama yanlış girdi seçimini kendiliğinden düzeltmez.

5. Sınıf dengesizliği

Herkese "hayatta kalmadı" diyen bir sınıflandırıcı ≈ %61,6 doğruluk alır, ama hayatta kalanların hiçbirini yakalayamaz.

* Sınıf ağırlıkları: hataların eğitimdeki ağırlığı değişir.
* Azaltarak örnekleme: bilgi kaybı olabilir.
* Çoğaltarak örnekleme: aynı örnekler ezberlenebilir.
* SMOTE: sentetik örnek; kategorik alanlarda uygunsuz değer üretebilir.

Örnekleme yalnızca eğitimde yapılır; testin doğal dağılımı korunur.

6. Son kontrol listesi

- [ ] Hedef girdilerden ayrıldı; X ve y aynı yolculara karşılık geliyor.
- [ ] Satır sayısı değişikliklerinin gerekçesi kaydedildi.
- [ ] Sayısal çıktılarda NaN veya sonsuz değer kalmadı.
- [ ] Eğitim ve test aynı sütun adı, sırası ve anlamına sahip.
- [ ] Doldurma, kodlama, ölçekleme yalnızca eğitimden öğrenildi.
- [ ] Ham veri korundu; formüller ve kurallar belgelendi.
- [ ] Yeni yolcuda eksik bilgi ve görülmemiş kategori davranışı denendi.

! İşlenmiş tablonun 891 satır ve sıfır eksik değerle bitmesi tek başına başarı göstergesi değildir: yanlış kodlama, hedef sızıntısı ya da kaymış satırlar hâlâ olabilir.

YBS 319 - Yapay Zekâ ve Öğrenen Algoritmalara Giriş
-Basit Doğrusal Regresyon-

Regresyon nedir?

Sayısal bir sonucu (fiyat, satış, teslim süresi, enerji tüketimi) onu açıklayan değişkenler üzerinden modellemek ve aradaki ilişkinin yapısını ölçmek.

Tahmin

"125 m², 8 yıllık dairenin fiyatı ne olur?" Yeni gözlemler için isabetli bir sayı.

Çıkarım

"Aynı yaştaki daireler arasında 1 m² fark fiyatı ortalama ne kadar değiştirir?"

Regresyon koşullu ortalamayı modeller: $E[Y \mid X = x]$ → "X değeri x olan gözlemlerde Y'nin ortalaması." Doğrusal regresyon iki amaca birlikte yanıt verebilir.

1. Model: popülasyon ve tahmin

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

Üstteki popülasyon modeli bilinmez. Alttaki örneklemden tahmin edilen doğrudur; ε yoktur, çünkü ŷ o x'teki gözlemlerin ortalamasının tahminidir.

- Y : bağımlı değişken, hedef
- X : bağımsız / açıklayıcı değişken, öznitelik
- β_0 : kesişim: X = 0 iken Y'nin beklenen değeri
- β_1 : eğim: X bir birim artınca beklenen değişim
- ε : hata terimi: X ile açıklanamayan bölüm
- $\hat{\beta}$: tahmin edilen katsayı ("beta şapka")

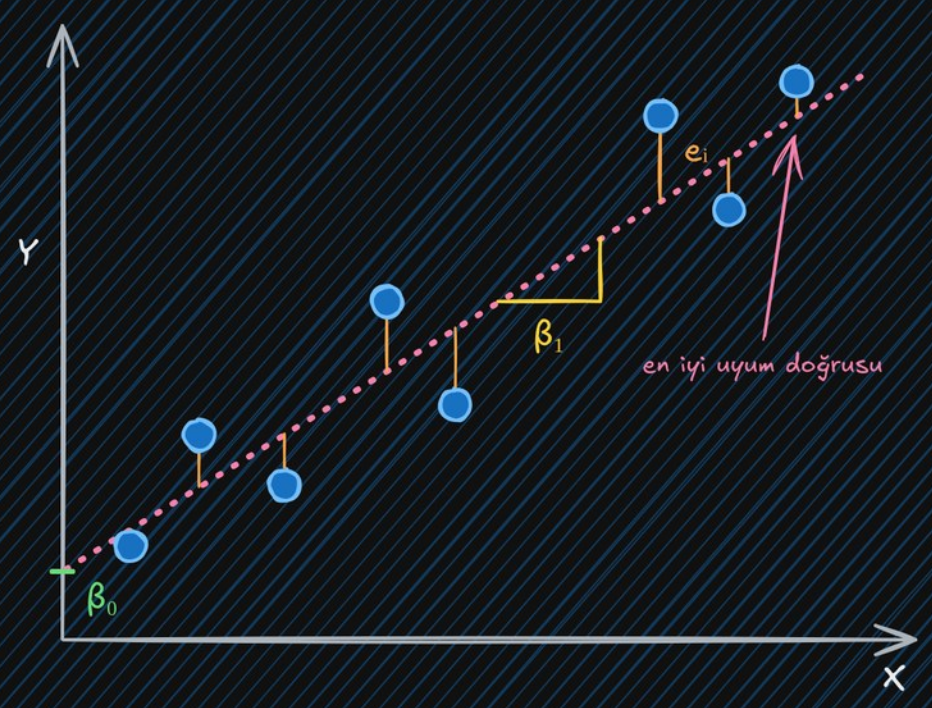

Hata: ε_i

$$\varepsilon_i = y_i - (\beta_0 + \beta_1 x_i)$$

Gözlemin gerçek popülasyon doğrusuna dikey uzaklığı. β'lar bilinmediği için hiçbir zaman hesaplanamaz.

Artık (kalıntı): e_i

$$e_i = y_i - \hat{y}_i$$

Gözlemin tahmin edilen doğruya dikey uzaklığı. Veriden hesaplanır; hataların gözlenebilir vekilidir.

Pozitif artık: gözlem doğrunun üstünde (model az tahmin etti) · Negatif artık: gözlem doğrunun altında (model fazla tahmin etti)

2. "En iyi doğru" ne demek?

Σe_i

Artıkların toplamı

× Kullanılamaz: pozitif ve negatif artıklar birbirini götürür; yatay bir doğru bile "kusursuz" görünür.

$\Sigma |e_i|$

Mutlak artıklar (LAD)

Aykırı değerlere daha dayanıklı, koşullu medyanı modeller; kapalı formda çözümü yok.

Σe_i^2

Kare artıklar (SSE)

✓ Tek ve kapalı formda çözüm; koşullu ortalamayı modeller. Bunu en küçük yapan yöntem: en küçük kareler (OLS).

Kare almanın bedeli:

Büyük hatalar orantısından fazla cezalandırılır: tek bir uç gözlem doğruyu kendine doğru çekebilir. ML kaynaklarında aynı ölçüt MSE = SSE / n olarak yazılır.

3. OLS çözümü ve elle hesap

$$\hat{\beta}_1 = S_{xy} / S_{xx} = \Sigma(x_i - \bar{x})(y_i - \bar{y}) / \Sigma(x_i - \bar{x})^2$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

- $\Sigma e_i = 0$: artıkların toplamı ve ortalaması sıfır.
- Doğru her zaman $(\bar{x}, \bar{y})$ noktasından geçer.
- Tahminlerin ortalaması $\bar{y}$'dir.
- Tek koşul $S_{xx} > 0$: x en az iki farklı değer almalı.

x: haftalık çalışma saati · y: quiz notu (10 üzerinden)

x	y	$x - \bar{x}$	$y - \bar{y}$	çarpım	$(x - \bar{x})^2$	$\hat{y}$	e
1	2	-2	-2	4	4	2,8	-0,8
2	4	-1	0	0	1	3,4	0,6
3	5	0	1	0	0	4,0	1,0
4	4	1	0	0	1	4,6	-0,6
5	5	2	1	2	4	5,2	-0,2
15	20	0	0	6	10	20	0

$\bar{x} = 3$, $\bar{y} = 4$ · $\hat{\beta}_1 = 6 / 10 = 0{,}6$ · $\hat{\beta}_0 = 4 - 0{,}6 \times 3 = 2{,}2$

$$\hat{y} = 2{,}2 + 0{,}6x$$

Haftada bir saat fazla çalışan öğrencilerin notu ortalamada 0,6 puan yüksek.

Daire verisi (30 daire): $S_{xy} = 1\,438{,}99$, $S_{xx} = 35\,367{,}47$ → $\hat{y} = -0{,}984 + 0{,}0407 \times$ alan. OLS kapalı formda, tek adımda çözülür; deneme yanılma yoktur.

! Doğrusallık katsayılarda aranır, değişkenlerde değil: $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \varepsilon$ de doğrusal regresyondur ve OLS ile çözülür.

YBS 319 - Yapay Zekâ ve Öğrenen Algoritmalara Giriş
-Regresyonu Yorumlamak ve Değerlendirmek-

1. Katsayıları yorumlamak

$\hat{y} = -0{,}984 + 0{,}0407 \times \text{alan}$ (fiyat milyon TL · alan m² · $R^2 = 0{,}814$ · n = 30)

Eğim: $\hat{\beta}_1 = 0{,}0407$

Net alanı 1 m² daha büyük olan daireler, ortalamada 40,7 bin TL daha pahalıdır (10 m² → 407 bin TL).

* "Ortalamada": tek bir dairenin değil, koşullu ortalamaların değişimi.
* "Daha büyük olan daireler": karşılaştırma; "daireyi büyütmek" (müdahale) değil.
* "Veri aralığında" (71–184 m²): dışına taşmak dışdeğerlemedir.
* Eğimin büyüklüğü birime bağlı: fiyat bin TL olsa eğim 40,7 olurdu.

Kesişim: $\hat{\beta}_0 = -0{,}984$

$x = 0$ için tahmin edilen değer: "0 m² dairenin fiyatı −984 bin TL". Böyle bir daire yok; bu değer yanlış değil, yalnızca yorumlanamaz.

* $x = 0$ anlamlı ve veri aralığına yakınsa yorumlanır: reklam yapılmayan hafta, ek kullanım yok.
* Anlamsız olsa da atılmaz: atılırsa doğru orijine zorlanır, eğim yanlı olur.
* Merkezleme: $\hat{y} = 4{,}286 + 0{,}0407 \times (\text{alan} - 129{,}5)$ → kesişim = $\bar{y}$

2. Model uyumu: R^2

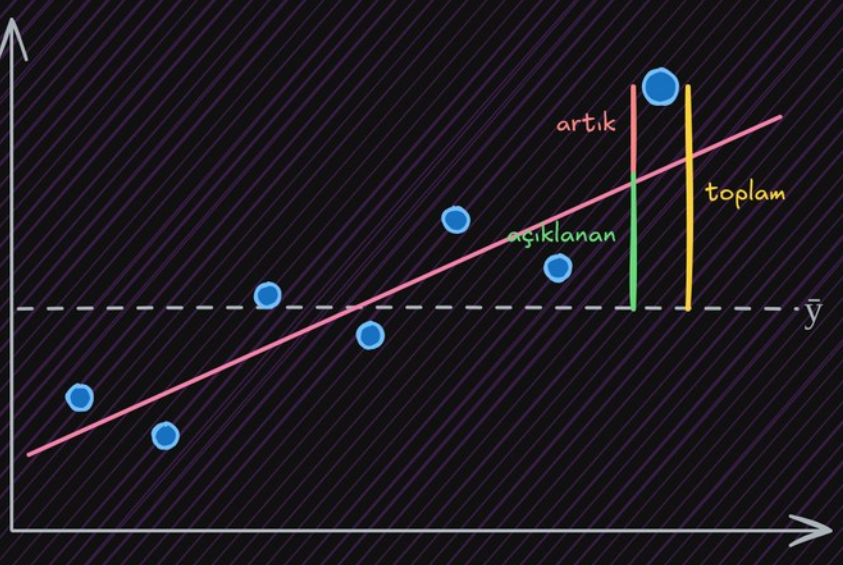

$(y_i - \bar{y}) = (\hat{y}_i - \bar{y}) + (y_i - \hat{y}_i)$

toplam sapma = modelin açıkladığı + artık

$SST = SSR + SSE$ 71,95 = 58,55 + 13,40

$R^2 = SSR / SST = 1 - SSE / SST = 0{,}814$

Fiyatların ortalama etrafındaki değişkenliğinin %81,4'ü alanla doğrusal bir ilişkiyle açıklanıyor. Kıyas noktası: herkese $\bar{y}$ tahmin eden en basit model.

3. Hata ölçüleri

RSE $\sqrt{(SSE / (n - 2))} = 0{,}692$
σ'nın tahmini; Y biriminde. Neden n − 2? İki parametre tahmin edildi.

MSE $(1/n) \Sigma e_i^2 = 0{,}447$
Birimi milyon TL²; doğrudan yorumu zor.

RMSE $\sqrt{MSE} = 0{,}668$
Hedefin biriminde.

MAE $(1/n) \Sigma |e_i| = 0{,}511$
Büyük hatalara daha az duyarlı; RMSE ≥ MAE.

Bunlar eğitim verisinde hesaplandı. Tahmin amaçlı modelde ölçüler modelin görmediği test verisinde raporlanır.

4. R^2 neyi söylemez?

* Yüksek R^2 modelin doğru olduğunu göstermez: eğri bir ilişkiye düz doğru da yüksek R^2 verebilir.
* Düşük R^2 ilişkinin önemsiz olduğunu göstermez: gürültülü alanlarda $R^2 = 0{,}10$ ile güçlü bir eğim olabilir.
* R^2 nedensellik ölçmez.
* Değişken eklemek R^2'yi asla düşürmez; işe yaramaz değişken bile biraz artırır.

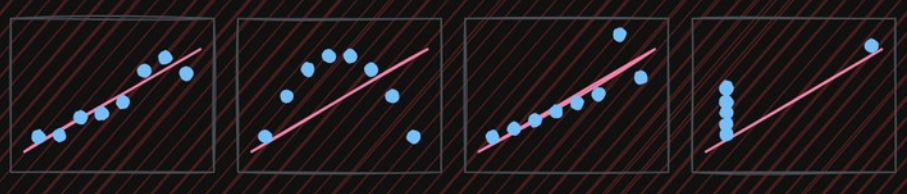

Anscombe dörtlüsü: aynı doğru ve R^2, tamamen farklı veri. Sayılardan önce veriyi çiz.

5. Varsayımlar ve artık grafiği

Doğrusallık
$E[Y|X]$ gerçekten $\beta_0 + \beta_1 X$

⚠ Tahminler bazı bölgelerde sistematik yüksek/düşük

Dışsallık
$E[\varepsilon|X] = 0$

⚠ Eğim yanlı; örneklem büyüse de düzelmez

Bağımsızlık
Hatalar birbirinden bağımsız

⚠ Standart hatalar fazla iyimser

Sabit varyans
$Var(\varepsilon|X) = \sigma^2$, her x için aynı

⚠ Katsayı yansız, standart hatalar yanlış

Normallik
$\varepsilon \sim N(0, \sigma^2)$

⚠ Küçük örneklemde testler yaklaşık hale gelir

Varsayımlar sağlandığında artık–tahmin grafiği sıfır çizgisi etrafında belirli bir biçimi olmayan bir bulut gibi görünür. Normallik X ya da Y ile değil, hata terimiyle ilgilidir.

6. Aykırı değer, kaldıraç ve etki

Aykırı değer

y yönünde uzak (büyük artık). Ortadaysa eğimi pek değiştirmez, RSE'yi büyütür.

Yüksek kaldıraç

x yönünde ortalamadan uzak gözlem; doğrunun üzerindeyse etkisi az.

Etkili gözlem

Çıkarıldığında katsayıları belirgin değiştirir (kesikli: o nokta olmadan). Büyük artık + yüksek kaldıraç; Cook uzaklığı.

! "Aykırı olması" bir gözlemi silmek için yeterli gerekçe değildir. Önce kayıt hatası olup olmadığı araştırılır (Hafta 4'teki aykırı değer kararları burada da geçerlidir).

YBS 319 - Yapay Zekâ ve Öğrenen Algoritmalara Giriş
-Çoklu Doğrusal Regresyon-

1. Doğrudan düzleme

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

Fiyatı yalnızca alanla açıklamak aynı alandaki yeni ve eski binaları aynı kefeye koymak demektir. X_1: net alan (m^2), X_2: bina yaşı (yıl).

$$\hat{y} = 1{,}590 + 0{,}0305 \times \text{alan} - 0{,}0661 \times \text{yaş}$$

$R^2 = 0{,}902$ · düzeltilmiş $R^2 = 0{,}895$ · $\hat{\sigma} = 0{,}511$ · $n = 30$

Neden ayrı ayrı basit regresyonlar kurmuyoruz? Açıklayıcı değişkenler birbiriyle ilişkili olduğunda her birinin katkısını ayırmak için aynı modelde olmaları gerekir.

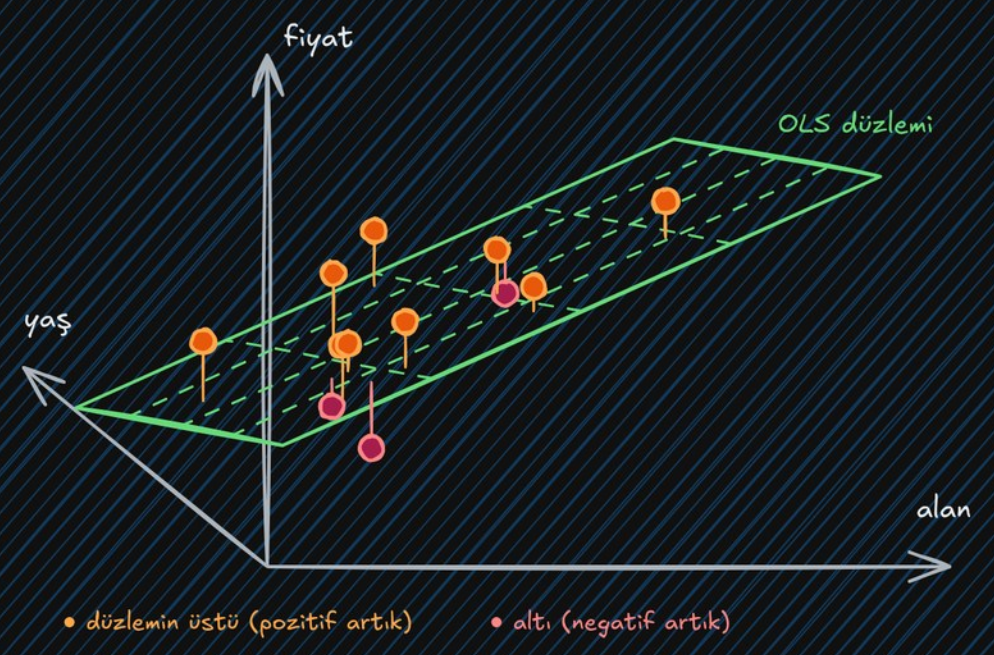

2. Katsayılar: "diğerleri sabitken"

$\beta_1 = 0{,}0305$ (alan)
Aynı yaştaki daireler karşılaştırıldığında, 1 m^2 daha büyük olan ortalamada 30,5 bin TL daha pahalı.

$\beta_2 = -0{,}0661$ (yaş)
Aynı alandaki daireler karşılaştırıldığında, binası 1 yıl daha eski olan ortalamada 66,1 bin TL daha ucuz.

$\beta_0 = 1{,}590$
Alan 0 m^2 ve yaş 0 iken beklenen fiyat: iki değişken birden sıfırdayken anlamsız.

"Sabit tutmak" istatistiksel bir karşılaştırmadır, deney değildir. Tahmin: 120 m^2, 10 yıllık daire → $1{,}590 + 0{,}0305 \times 120 - 0{,}0661 \times 10 = 4{,}594$ milyon TL (basit model: 3,898).

3. Alanın katsayısı neden 0,0407'den 0,0305'e düştü?

Basit model: 40,7 bin TL / m^2
"1 m^2 daha büyük bir daire ortalamada ne kadar pahalı?" Büyük dairelerin genellikle daha yeni binalarda olduğu gerçeği bu karşılaştırmaya dahil.

Çoklu model: 30,5 bin TL / m^2
"Aynı yaştaki iki daireden 1 m^2 büyük olan ortalamada ne kadar pahalı?" Yaş farkının fiyata yansıyan kısmı ayrılmış.

$$\tilde{\beta}_1 = \hat{\beta}_1 + \hat{\beta}_2 \cdot \delta \qquad 0{,}0407 = 0{,}0305 + (-0{,}0661) \times (-0{,}1535)$$

$\delta = -0{,}1535$: 10 m^2 daha büyük daireler ortalamada 1,5 yıl daha yeni binalarda. Basit modeldeki 40,7 bin TL'nin ≈ 10,1 bin TL'si alanın değil, büyük dairelerin yeni olmasının payıdır: dışlanmış değişken yanlılığı.

Yanlılık için iki koşul birlikte gerekir: dışlanan değişken Y'yi etkilemeli VE dahil edilen değişkenle ilişkili olmalı.

4. Matris gösterimi

$$y = X\beta + \varepsilon \quad \Rightarrow \quad \hat{\beta} = (X^T X)^{-1} X^T y$$

* X: 30 × 3 tasarım matrisi (birler sütunu, alan, yaş). Birler sütunu kesişimi üretir.
* Çözüm için X'in sütunları doğrusal olarak bağımsız olmalı: $n \geq p + 1$ ve tam çoklu bağlantı yok.
* Alan hem m^2 hem ft^2 olarak girerse $X^T X$ tekil olur, OLS tek çözüm vermez.
* Artık vektörü sütun uzayına diktir: $X^T e = 0$.

5. Çoklu doğrusal bağlantı

$$VIF_j = 1 / (1 - R_j^2)$$

* Değişkenler çok benzerse katsayıların standart hataları √VIF kat büyür; katsayılar örneklemden örnekleme sallanır (menteşe).
* Amaç tahminse çoğu zaman sorun değildir.
* Amaç yorumsa: daha fazla veri, değişkenlerden birini çıkarmak, anlamlı bir indekste birleştirmek.

Örneğimizde r(alan, yaş) = −0,604.

6. Uyum: düzeltilmiş R^2 ve F testi

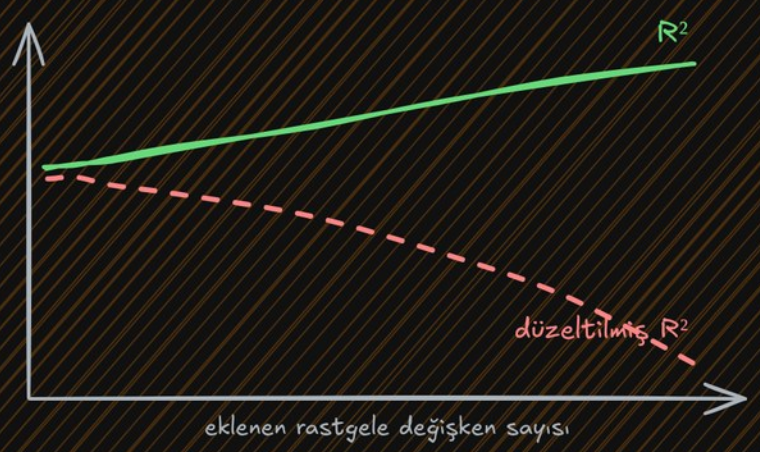

$$\bar{R}^2 = 1 - (1 - R^2)(n - 1)/(n - p - 1)$$

Her ek değişken için serbestlik derecesi kaybını cezalandırır. 30 gözlemle 20 rastgele değişkende R^2 1'e tırmanır: model gürültüyü ezberler (aşırı öğrenme).

F testi · H_0: $\beta_1 = \beta_2 = 0$ → $F(2, 27) = 124{,}1$, $p < 0{,}001$

Model bir bütün olarak işe yarıyor mu? Çok sayıda t testinde tesadüfen anlamlı çıkma riskine karşı.

	Tahmin	Std. hata	t	p	%95 güven aralığı
Kesişim	1,590	0,637	2,50	0,019	[0,282 ; 2,898]
Alan (m^2)	0,0305	0,00341	8,95	< 0,001	[0,0235 ; 0,0375]
Yaş (yıl)	−0,0661	0,0134	−4,92	< 0,001	[−0,0937 ; −0,0386]

p değeri "H_0'ın doğru olma olasılığı" değildir ve etkinin büyüklüğünü ölçmez.

7. "Doğrusal" modeli genişletmek

Kategorik değişken
"Asansör var mı?" → 0/1 kukla: + β_3·Asansör. Aynı alan ve yaştaki daireler arasındaki ortalama fark; düzlemi paralel kaydırır.

Etkileşim
Bir değişkenin etkisi diğerine bağlıysa çarpım terimi eklenir ($X_1 \cdot X_2$): eğim gruba göre değişebilir.

Eğri ilişki
X^2 veya log X eklenebilir: katsayılarda doğrusal kaldığı için aynı $\hat{\beta} = (X^T X)^{-1} X^T y$ ile çözülür.

! Her değişkeni eklemek doğru değildir: açıklayıcı değişkenin sonucu olan değişkenleri modele koymak katsayının anlamını bozar. Hangi değişkenin neden modelde olduğunu söyleyebilmelisin.